Défi IA sur la mission ARIEL par le CNES et l'IAP

Trouver de l'eau et des nuages dans les atmosphères d'exoplanètes

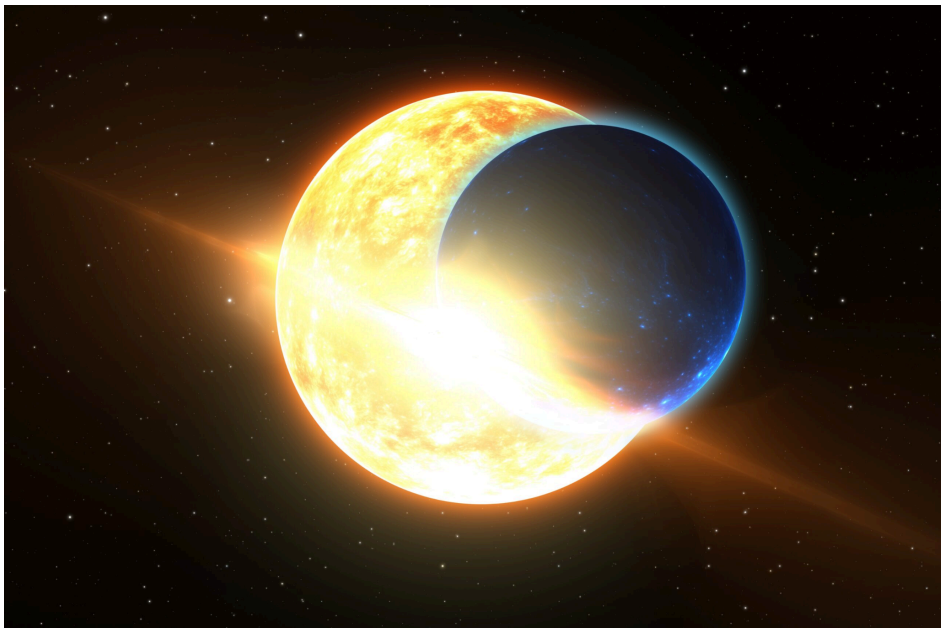

Réalisé par :

Florent Cheyron - Mathis Cotonnec - Damien Peres - Solo Peyret

Année universitaire : 2025 - 2026

Master 2 MAS

Professeur référent : Monsieur Laurent Rouvière

I. Introduction 4
I.1. Contexte scientifique : La spectroscopie de transit 5
I.2. Le défi de l'analyse de données : Vers une approche IA 5
I.3. Description technique des données et formalisation 6
I.4. Plan 8
II. Méthodologie et Démarche Scientifique 8
II.1. Point de départ : La solution de référence (Baseline) 8
II.1.1 Pré-traitement et structure des données 9
II.1.2 Feature Engineering : enrichissement des spectres 10
II.1.3 Normalisation et mise à l'échelle des données 10
II.2 Stratégie de modélisation de machine learning classique 12
II.2.1 Machines à Vecteurs de Support 12
II.2.2 Méthodes d'ensembles 13
II.2.3 Forêt aléatoire : 13
II.2.3 Algorithme de Boosting, XGBoost 14
II.2.4 CatBoost et enrichissement des caractéristiques 15
II.3 Stratégies de modélisation Deep Learning 16
II.3.1 Motivation et Cohérence du pré-traitement 16
II.3.2 Évolution de l'architecture : Du CNN simple au modèle Hybride 16
II.3.3 Analyse théorique des stratégies de sortie 16
II.3.4 Limites de l'augmentation de données et Protocole d'optimisation 17
II.3.5 Performances finales et Convergence 17
II.4 Protocole d'évaluation 19
III. Analyse des Résultats 20
III.1 Analyse Exploratoire (EDA) 20
III.2 Performance des Modèles 21
III.2.1 Synthèse des résultats 22
III.2.2 Analyse des performances 22
III.3 Analyse Métier 23
III.3.1 Hiérarchie des prédicteurs 24
III.3.2 Analyse des Erreurs et Cas Limites 24
IV. Conclusion Générale 26
V. Bibliographie 27

I. Introduction

L'astrophysique voit arriver ces dernières années une révolution. Si le XXe siècle a été celui de la découverte de l'Univers à grande échelle, le XXIe siècle s'annonce comme celui de la caractérisation des exoplanètes et de notre univers. Avant 1995, notre seule référence était le Système Solaire : des petites planètes rocheuses près du Soleil (Terre, Mars) et des géantes gazeuses lointaines (Jupiter, Saturne). Depuis la confirmation de la première exoplanète orbitant autour d'une étoile de type solaire (51 Pegasi b), plus de 5000 exoplanètes ont été recensées. Cette abondance a révélé une diversité inattendue : des "Jupiters chauds", des "Super-Terres" rocheuses, ou encore des "mini-Neptunes" gazeuses.

A la suite de cette première découverte, la course aux exoplanètes a commencé. D'abord au sol, puis avec des télescopes spatiaux comme Kepler (NASA). On est passé de la découverte anecdotique à la statistique de masse. Parmi les différentes techniques employées, la méthode du transit, utilisée notamment par la mission ARIEL, est à l'origine de la majorité des exoplanètes découvertes. Le principe s'apparente à une éclipse miniature. Si l'orbite d'une planète est alignée avec notre ligne de visée, celle-ci passe périodiquement devant son étoile, bloquant une infime partie de la lumière. Ce n'est pas une éclipse totale, mais une baisse de luminosité mesurable qui forme une courbe caractéristique. C'est cette méthode qui est responsable de la majorité des 5000 exoplanètes recensées à ce jour, révélant une diversité inattendue.

Cependant, comme le soulignent Tinetti et al.[1] dans la présentation de la mission ARIEL (Atmospheric Remote-sensing Infrared Exoplanet Laboratory), le simple recensement ne suffit plus, l'astrophysique est passée d'une ère de découverte à une ère de caractérisation. Pour comprendre la formation et l'évolution de notre univers, il est impératif de sonder leur composition chimique. Savoir qu'une planète existe, connaître sa masse et son rayon, c'est bien, mais c'est insuffisant. Une planète qui a la même densité que l'eau, cela peut être deux choses totalement différentes :

- Une planète Océan composée à 100% d'eau.
- Un petit noyau rocheux entouré d'une énorme atmosphère d'hydrogène. Sans regarder la chimie de l'atmosphère, on ne peut pas trancher. C'est ce qu'on appelle la dégénérescence.

Le but d'ARIEL : Sortir de cette ambiguïté en lisant le spectre pour dire "Il y a de l'eau", "Il y a du méthane", etc. Pour comprendre les mécanismes de formation planétaire et évaluer leur potentiel d'habitabilité.

Ce projet s'inscrit au cœur de cette démarche scientifique, en lien direct avec la future mission spatiale ARIEL de l'Agence Spatiale Européenne (ESA). Prévue pour un lancement à l'horizon 2029, ARIEL sera le premier observatoire spatial entièrement dédié à l'étude des atmosphères d'un échantillon large et diversifié d'exoplanètes. Mais cette mission soulève un défi majeur de traitement de données : comment extraire, de manière fiable et automatisée, des signatures chimiques ténues dans des signaux ?

---

[1] Tinetti, G. et al., “ARIEL: Enabling planetary science across light-years”, Experimental Astronomy, 46, 135–209, 2018.

C'est à cette question que répond le "Défi IA 2025", en proposant une approche basée sur l'apprentissage supervisé pour détecter deux composantes clés : la vapeur d'eau et les nuages. Ce rapport présente la méthodologie et les résultats d'une telle approche, confrontant les techniques d'intelligence artificielle aux réalités de l'astrophysique.

I.1. Contexte scientifique : La spectroscopie de transit

Pour comprendre la nature des données manipulées dans cette étude, il est nécessaire de détailler le principe physique de la détection : la spectroscopie de transmission.

Si la planète possède une atmosphère, une fraction de la lumière de l'étoile traverse cette couche gazeuse avant de nous parvenir. Durant ce trajet, les atomes et molécules présents dans l'atmosphère absorbent la lumière à des longueurs d'onde spécifiques, correspondant à leurs niveaux d'énergie quantiques.

Dans ce projet, nous exploitons des spectres de transit pour détecter la présence d'eau et de nuages dans l'atmosphère d'exoplanètes. Un spectre est la représentation de l'intensité lumineuse d'une source en fonction de la longueur d'onde (ou de la fréquence) : plutôt qu'une mesure globale, on décompose la lumière en couleurs (longueurs d'onde) et l'on mesure combien de lumière est reçue à chacune d'elles. La matière (gaz, molécules, poussières) n'absorbe ni n'émet la lumière de manière uniforme, elle laisse des empreintes spécifiques sous forme de lignes ou bandes d'absorption/émission à des longueurs d'onde bien déterminées. Ces signatures spectrales permettent d'identifier la composition (ex :. H_2O, CO, CH_4), d'estimer des propriétés physiques (température, pression, dynamique) et de détecter des phénomènes atmosphériques (nuages/brumes qui aplatissent le contraste du spectre).

La région de l'infrarouge, ciblée par les instruments d'ARIEL, est particulièrement riche en informations car de nombreuses molécules (eau, méthane, dioxyde de carbone) y possèdent des bandes d'absorption intenses.

Dans le contexte de la spectroscopie de transit, une fraction de la lumière stellaire traverse l'atmosphère planétaire avant d'atteindre l'instrument. Si l'atmosphère contient de l'eau, on observe des creux (diminutions de flux) aux longueurs d'onde où l'H_2O absorbe fortement. Concrètement, la planète "parait" plus grande à ces longueurs d'onde car son atmosphère est opaque. À l'inverse, si l'atmosphère est riche en nuages ou en brumes, ces particules solides ou liquides en suspension diffusent la lumière de manière plus uniforme sur tout le spectre. Ces signatures sont alors atténuées : le spectre devient plus plat et moins contrasté, rendant la détection des molécules gazeuses beaucoup plus difficile.

I.2. Le défi de l'analyse de données : Vers une approche IA

Historiquement, l'analyse des atmosphères des exoplanètes repose sur des méthodes d'inversion dites de "retrieval atmosphérique". Ces techniques consistent à générer des milliers, voire des millions de modèles théoriques d'atmosphères en faisant varier les paramètres (température, abondances chimiques), et à les comparer aux observations via des méthodes statistiques bayésiennes (type Nested Sampling ou Méthode de Monte-Carlo par chaînes de Markov). Bien que rigoureuses, ces méthodes sont extrêmement coûteuses en temps de calcul (plusieurs heures ou jours par planète).

Avec l'arrivée de missions comme ARIEL, qui fourniront des données pour des milliers de planètes, ces méthodes traditionnelles sont inadaptées pour un traitement systématique en temps réel sur des milliers de données. L'Intelligence Artificielle, et plus spécifiquement l'apprentissage automatique (Machine Learning), offre une alternative prometteuse. En apprenant la relation complexe entre la forme d'un spectre et les propriétés physiques de l'atmosphère sur une base de données simulée, un modèle d'IA peut effectuer des prédictions en une fraction de seconde.

Cependant, le passage à l'IA est compliqué. Les signaux sont caractérisés par :

- Un faible rapport signal sur bruit : La signature de l'atmosphère ne représente souvent que quelques dizaines de ppm (parties par million) du flux total de l'étoile.
- Des dégénérescences **:** Différentes combinaisons de paramètres physiques peuvent produire des spectres quasi-identiques (par exemple, une haute couverture nuageuse peut masquer la présence d'eau, mimant une atmosphère sèche).

La problématique centrale de ce rapport est donc : Comment concevoir un modèle d'apprentissage capable de détecter ces signatures subtiles et de classifier robustement la présence d'eau et de nuages malgré le bruit inhérent aux observations ?

I.3. Description technique des données et formalisation

Les données mises à disposition pour ce défi sont des simulations réalistes des observations attendues d'ARIEL. Elles se décomposent en deux types d'informations.

1.3.1. Les Données Spectrales (Séries Temporelles)

Dans notre jeu de données, un spectre complet se présente comme une courbe discrète. Pour chaque longueur d'onde lambda (en µm), on dispose d'un triplet :

- wavelength (µm) : la longueur d'onde lambda;
- flux : l'intensité mesurée à cette longueur d'onde (ici, la profondeur spectroscopique du transit, grandeur adimensionnée) ;
- uncertainty : l'incertitude (erreur type) associée à la mesure du flux au même lambda.

La valeur du spectre à une longueur d'onde donnée est donc le flux mesuré à lambda, accompagné de son incertitude. Les creux cohérents de flux sur des fenêtres de lambda montrent une absorption moléculaire (ex. H_2O), tandis qu'un aplatissement global (faible contraste) est lié à la présence de nuages.

Le jeu de données comprend 3000 spectres d'entraînement et 1032 de test. Chaque spectre contient 52 points, couvrant une large bande spectrale (visible et infrarouge). Cette faible résolution spectrale (52 points seulement) est une contrainte forte : elle oblige les modèles à être très sensibles à la forme globale plutôt qu'à des raies fines isolées.

1.3.2. Les Variables Auxiliaires (Données Tabulaires)

Chaque spectre est accompagné de cinq descripteurs physiques :

1. Masse et Rayon de l'étoile : Ces paramètres déterminent l'intensité du signal de transit. Une petite étoile rend la détection de l'atmosphère d'une planète plus aisée (contraste plus fort).
2. Température de l'étoile : Elle influence directement la température de la planète et donc la chimie atmosphérique (l'eau est-elle sous forme de vapeur ou de glace ?).
3. Masse de la planète : liée à la gravité de surface. Une forte gravité tend à "tasser" l'atmosphère, réduisant l'amplitude des signatures spectrales.
4. Demi-grand axe : La distance à l'étoile, qui conditionne l'irradiation reçue.

Ces variables auxiliaires ne contiennent pas directement l'information sur l'eau ou les nuages, mais elles fournissent le contexte nécessaire à l'interprétation du spectre. Un modèle intelligent doit apprendre à moduler son analyse spectrale en fonction de ce contexte (par exemple, s'attendre à des signaux plus faibles pour des planètes massives).

1.3.3. Les Cibles (Targets)

Le problème est formalisé comme une classification binaire multi-label. Pour chaque observation X, nous devons prédire un vecteur Y = [y_{eau}, y_{nuage}] où y appartient à {0, 1}.

L'analyse exploratoire des variables cibles met en évidence une répartition uniforme au sein du jeu d'entraînement. Chacune des quatre combinaisons de labels possibles ([0,0], [1,0], [0,1], [1,1]) est représentée par exactement 750 échantillons.

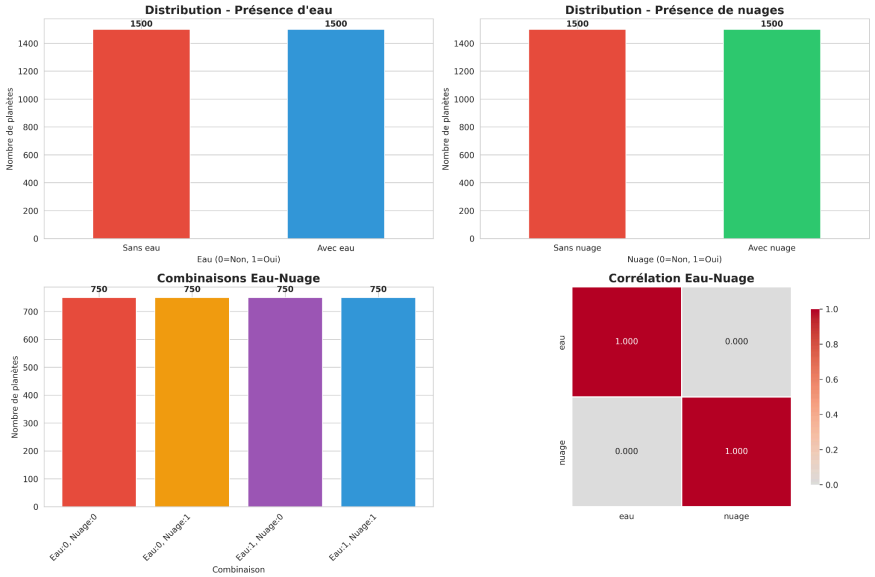

Cette symétrie parfaite démontre que ce sont des données générées pour ce défi. En effet, dans un contexte astrophysique réel, la prévalence de l'eau ou des nuages suivrait une distribution asymétrique dictée par les lois de la formation planétaire. Cependant, cet

"équilibre artificiel" constitue un atout méthodologique très important pour l'apprentissage supervisé :

- Neutralisation des biais : Il élimine le risque de biais de classe majoritaire, empêchant les modèles d'optimiser leur score par de simples stratégies probabilistes (comme prédire systématiquement la classe la plus fréquente).
- Apprentissage profond : Il contraint les algorithmes à chercher l'information discriminante uniquement dans la morphologie des spectres et les variables physiques, plutôt que dans les statistiques d'occurrence.
- Validation des métriques **:** Il justifie pleinement l'utilisation de métriques standards telles que l'exactitude (accuracy) et le F1-Score, qui ne seront pas faussées par un déséquilibre initial des classes.

I.4. Plan

Afin de répondre à ce défi scientifique et technique, ce rapport s'articule autour de la démarche suivante :

Dans une première partie, nous détaillerons la méthodologie adoptée. Nous présenterons les techniques de prétraitement appliquées pour nettoyer et normaliser les données spectrales. Nous justifierons ensuite le choix de nos modèles prédictifs, en comparant des approches statistiques classiques (SVM, méthodes d'ensemble type XGBoost) à des architectures d'apprentissage profond (Réseaux de Neurones Convolutifs 1D), spécifiquement conçues pour exploiter la cohérence des spectres.

La seconde partie sera consacrée à l'analyse critique des résultats. Au-delà des métriques de performance brute, nous chercherons à interpréter le comportement des modèles : quelles sont les longueurs d'onde déterminantes ? Comment le contexte physique de la planète influe-t-il sur la fiabilité des prédictions ? Nous analyserons également les cas d'erreurs pour comprendre les limites actuelles de l'approche.

Enfin, nous conclurons en synthétisant les apports de cette étude et en proposant des pistes d'ouverture pour améliorer la robustesse de la détection atmosphérique automatisée dans le cadre de la mission ARIEL.

II. Méthodologie et Démarche Scientifique

La démarche adoptée pour ce défi repose sur une confrontation entre des approches classiques (Machine Learning sur caractéristiques) et des approches d'apprentissage profond (Deep Learning). Cette section détaille les choix et les stratégies de traitement du signal mises en œuvre, en justifiant leur pertinence par rapport au problème.

II.1. Point de départ : La solution de référence (Baseline)

Avant d'explorer des modèles complexes, il est méthodologiquement indispensable d'établir un point de comparaison. Nous avons donc analysé et reproduit la solution de référence

fournie par les organisateurs du défi. Cette approche initiale permet de valider la chaîne de traitement et de définir un niveau de performance minimum à dépasser.

II.1.1 Pré-traitement et structure des données

L'approche de la solution de référence repose sur un pré-traitement volontairement simple des données. L'objectif de cette baseline est de fournir un point de comparaison clair et reproductible, plutôt que d'exploiter de manière détaillée toutes les informations physiques disponibles. Ce choix permet de mieux comprendre l'impact direct des données brutes sur les performances des modèles, tout en limitant la complexité de la chaîne de traitement.

Les données spectrales sont fournies sous la forme de tableaux de dimension (N,52,3), où N correspond au nombre d'observations. Pour chaque exoplanète, le spectre est mesuré sur 52 longueurs d'onde couvrant le visible et l'infrarouge. À chaque longueur d'onde sont associées la profondeur du transit (flux) et l'incertitude de mesure. Afin de simplifier cette structure, seuls les flux spectraux sont conservés dans la baseline. Chaque spectre est ainsi représenté par un vecteur de 52 valeurs. Les incertitudes ne sont pas utilisées à ce stade, ce qui revient à considérer que l'information principale réside dans la forme globale du spectre, indépendamment de la qualité individuelle des mesures.

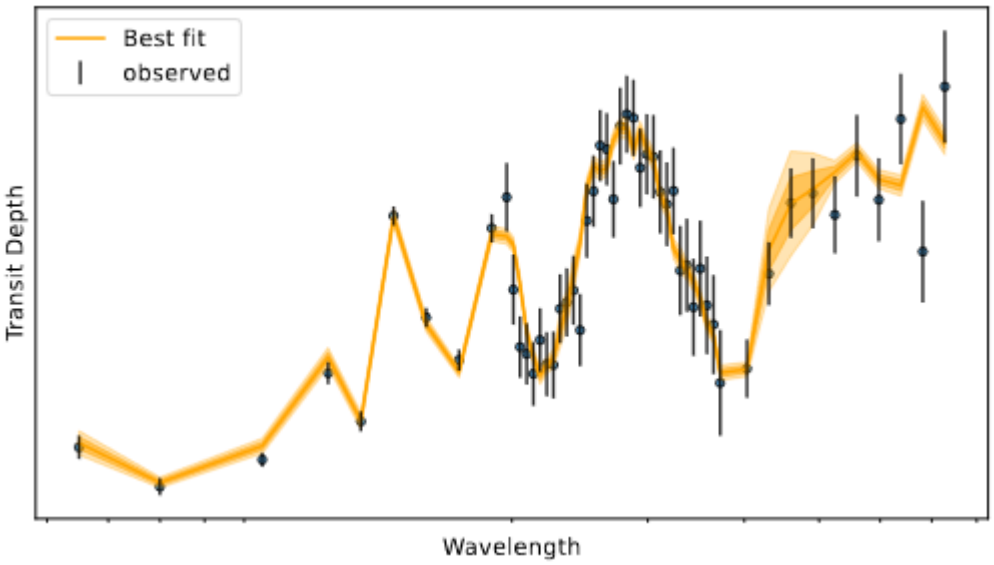

Les vecteurs spectraux obtenus sont ensuite concaténés avec les variables auxiliaires décrivant le système planétaire et stellaire (masse et rayon de l'étoile, température, masse de la planète, distance planète–étoile). Cette concaténation permet d'exploiter simultanément l'information spectrale et le contexte physique global, sans transformation spécifique des variables auxiliaires. Enfin, la gestion des éventuelles valeurs manquantes est réalisée à l'aide de méthodes simples d'imputation, suffisantes pour assurer la stabilité numérique des modèles.

Dans l'ensemble, ce pré-traitement peut être qualifié de « naïf » au sens où il ne tire pas pleinement parti de toutes les informations disponibles dans les données, en particulier des incertitudes de mesure et de la structure séquentielle du spectre. Toutefois, il constitue une base de référence essentielle, permettant d'évaluer les gains apportés par des stratégies de

pré-traitement et de feature engineering plus élaborées, qui seront introduites dans les sections suivantes.

II.1.2 Feature Engineering : enrichissement des spectres

La solution de référence repose sur une utilisation directe des valeurs spectrales qui peut montrer certaines limites lorsqu'il s'agit de détecter des signatures physiques faibles et localisées, comme les bandes d'absorption moléculaire. Afin d'améliorer l'exploitation de la forme des spectres, un travail de feature engineering a été mis en place, tout en conservant une approche simple et adaptée aux données disponibles.

L'objectif principal de cet enrichissement est de ne pas se limiter aux valeurs absolues du flux mesuré à chaque longueur d'onde, mais de prendre en compte les variations locales du spectre. En astrophysique, la présence de molécules telles que la vapeur d'eau se traduit par des structures caractéristiques, comme des creux ou des changements rapides de flux sur des intervalles spectraux restreints. Ces informations peuvent être partiellement perdues lorsque seules les valeurs brutes du spectre sont utilisées.

C'est dans ce contexte, nous avons choisi de calculer des dérivées spectrales discrètes (différences finies). Pour chaque spectre, représenté par un vecteur de 52 points, on calcule la différence de flux entre deux longueurs d'onde consécutives. Cette opération permet d'obtenir un vecteur décrivant les pentes locales du spectre, où les valeurs négatives sont généralement associées à des zones d'absorption, tandis que les valeurs positives traduisent une augmentation du flux. Les dérivées spectrales présentent plusieurs avantages : elles permettent de décrire la forme du spectre de manière plus robuste, indépendamment de son amplitude globale, et elles sont bien adaptées à la faible résolution spectrale des données. En pratique, cette approche montre les variations relatives du signal, qui donnent souvent plus d'informations que les valeurs absolues, tout en restant compatible avec des modèles de Machine Learning classiques.

Les vecteurs de dérivées sont ensuite concaténés aux spectres initiaux et aux variables auxiliaires décrivant le système planétaire et stellaire. Le vecteur de caractéristiques final combine ainsi trois types d'informations complémentaires :

- les valeurs du flux spectral
- les dérivées spectrales
- les variables auxiliaires, qui fournissent le contexte physique global.

Cette représentation enrichie permet aux modèles de disposer d'un espace de caractéristiques plus informative.

II.1.3 Normalisation et mise à l'échelle des données

Une étape essentielle du pré-traitement des données consiste à assurer une mise à l'échelle cohérente des variables. Dans notre cas, les données manipulées sont très hétérogènes : d'un côté, les spectres de transit décrivent des profondeurs spectroscopiques de l'ordre de quelques dizaines à centaines de parties par million ; de l'autre, les variables auxiliaires correspondent à des grandeurs physiques telles que des masses, des rayons ou des températures, exprimées sur des échelles très différentes. Sans normalisation appropriée, ces différences d'ordre de grandeur pourraient biaiser l'apprentissage des modèles.

Les variables auxiliaires sont traitées différemment des signaux. Ces paramètres (masse et rayon de l'étoile, température stellaire, masse de la planète, demi-grand axe) n'ont pas la même interprétation physique que les points spectraux et ne doivent pas être normalisés de manière identique. Une mise à l'échelle globale, comme une standardisation ou une normalisation, est appliquée afin de garantir que chaque variable contribue de manière équilibrée à l'apprentissage.

L'objectif n'est pas de proposer un traitement optimal au sens astrophysique, mais de garantir la stabilité numérique des algorithmes, la comparabilité des expériences et la reproductibilité des résultats.

Les différentes normalisations que nous avons utilisées sont :

<u>La Standardisation Globale</u>

Pour les variables auxiliaires (masses, températures, demi-grand axe), nous avons utilisé une approche classique de standardisation sur l'ensemble du jeu de données.
Pour chaque caractéristique, (par exemple la température), nous calculons la moyenne et l'écart-type sur l'ensemble des exemples d'entraînement.

Les variables physiques du dataset présentent des ordres de grandeur extrêmes et hétérogènes : la masse stellaire est de l'ordre de 10^30, tandis que la température est de l'ordre de 10^3.

La standardisation ramène toutes les caractéristiques à une échelle commune (centrée sur 0, écart-type de 1), mettant toutes les variables sur un pied d'égalité et qui permet de régler les poids de manière équilibrée.

<u>La Normalisation Locale par Instance</u>

Pour le traitement des séries temporelles spectrales (flux et incertitudes), nous avons implémenté une normalisation Z-score calculée individuellement pour chaque exoplanète.

Nous calculons la moyenne mu et l'écart-type sigma spécifiques à ce spectre, puis nous

$$\hat{x}_t^{(i)} = \frac{x_t^{(i)} - \mu_i}{\sigma_i + \epsilon}$$

appliquons la transformation :

où epsilon est une constante. On effectue cette opération pour chaque échantillon.
Cette méthode est liée à la physique des signaux. La profondeur du flux est proportionnelle au rapport des surfaces. Une petite planète devant une petite étoile peut produire une baisse de luminosité similaire à une grosse planète devant une grosse étoile.
Cependant, la signature chimique se manifeste par la forme des creux d'absorption et non par l'intensité absolue du signal. En normalisant par instance, nous effaçons l'information d'échelle absolue liée à la taille de l'étoile pour forcer le réseau de neurones à se concentrer uniquement sur la morphologie du signal.
Cette technique est très utilisée en Deep Learning et très souvent dans le traitement du signal audio et biomédical (EEG/ECG) pour normaliser des signaux dont l'amplitude varie fortement d'un patient à l'autre, tout comme nos étoiles varient en luminosité.

II.2 Stratégie de modélisation de machine learning classique

Après la phase de pré-traitement et de construction des caractéristiques, l'étape suivante consiste à choisir des modèles d'apprentissage adaptés à la nature des données et aux objectifs scientifiques du projet. Dans ce travail, nous avons fait le choix, pour commencer, de nous concentrer sur des approches de Machine Learning classique, dites feature-based, c'est-à-dire des modèles qui exploitent explicitement les caractéristiques construites à partir des spectres et des variables auxiliaires.

Ce choix est principalement motivé par la nature du problème étudié. Les spectres de transit disponibles sont de faible résolution (52 points spectraux) et les signatures atmosphériques recherchées sont faibles et bruitées. Dans ce contexte, des modèles simples mais robustes sont souvent plus adaptés que des approches plus complexes. De plus, les modèles classiques permettent une meilleure compréhension du comportement des prédictions, ce qui est un avantage important dans un cadre scientifique.

Les modèles retenus doivent être capables de gérer : des données de dimension relativement élevée (spectres + dérivées + variables auxiliaires); des relations non linéaires entre les variables; un bruit important dans les observations.

Pour répondre à ces contraintes,nous allons voir deux grandes familles de modèles qui ont été explorées : les machines à vecteurs de support (SVM) et les méthodes d'ensemble, telles que les forêts aléatoires et les algorithmes de boosting.

II.2.1 Machines à Vecteurs de Support

Les machines à vecteurs de support (Support Vector Machines, SVM) constituent un choix pertinent pour ce type de problème. En effet, chaque observation est décrite par un grand nombre de variables. Dans notre cas, chaque planète est représentée par les valeurs du spectre, les dérivées spectrales, ainsi que les variables auxiliaires décrivant le système planétaire. On se retrouve donc dans un espace de dimension relativement élevée, ce pour quoi les SVM sont particulièrement bien adaptés.

Le principe des SVM consiste à chercher une frontière de décision qui sépare au mieux les différentes classes, tout en maximisant la distance entre cette frontière et les observations les plus proches. Cette distance, appelée marge, joue un rôle important dans la capacité du modèle à bien généraliser sur de nouvelles données. Dans ce contexte, les signaux sont bruités et parfois très proches les uns des autres, cette propriété permet de limiter le sur-apprentissage et d'obtenir des prédictions plus stables.

Toutefois, dans le cadre de ce projet, cette approche n'a pas été retenue pour l'analyse finale. En effet, les SVM considèrent les spectres comme des vecteurs globaux de caractéristiques et ne permettent pas d'exploiter explicitement la structure séquentielle et locale du signal spectral, qui joue un rôle central dans l'identification des signatures moléculaires. L'étude s'est donc concentrée sur des modèles capables d'intégrer cette information morphologique, en particulier les réseaux de neurones convolutifs unidimensionnels, mieux adaptés à la topologie des données spectrales.

Les SVM sont ainsi présentés ici à titre de référence méthodologique, sans faire l'objet d'une implémentation ni d'une évaluation quantitative dans ce travail.

II.2.2 Méthodes d'ensembles

En complément des machines à vecteurs de support, nous avons également exploré des méthodes d'ensemble, et plus particulièrement les forêts aléatoires (Random Forest) ainsi que des algorithmes de type Gradient Boosting. Ces méthodes reposent sur une idée simple. Plutôt que de s'appuyer sur un seul modèle, on combine les prédictions de plusieurs modèles plus simples afin d'obtenir un résultat global plus robuste et plus stable.

Dans notre cas, les modèles de base utilisés sont des arbres de décision. Un arbre de décision peut être vu comme une succession de règles simples qui partitionnent les données en fonction des valeurs des variables d'entrée. Pris individuellement, ces arbres sont faciles à interpréter, mais ils peuvent être sensibles au bruit et aux variations des données. Les méthodes d'ensemble permettent de corriger cette faiblesse en combinant plusieurs arbres construits de manière différente.

II.2.3 Forêt aléatoire :

Les forêts aléatoires reposent sur le principe du bagging. Concrètement, plusieurs arbres de décision sont entraînés sur des sous-ensembles aléatoires des données et des variables. Chaque arbre fournit une prédiction, et la décision finale est obtenue en agrégeant l'ensemble des prédictions. Cette stratégie permet de réduire la variance du modèle et de limiter le sur-apprentissage. Dans le cadre de ce projet, les forêts aléatoires sont particulièrement bien adaptées, car elles peuvent gérer simultanément des données spectrales et des variables auxiliaires, tout en capturant des relations non linéaires entre ces différentes informations, sans nécessiter de pré-traitement complexe.

Application dans le projet :
Dans notre implémentation, les forêts aléatoires ont été utilisées comme modèle de référence. Le problème étant formulé comme une classification binaire multi-label, nous avons entraîné deux forêts distinctes :

- une forêt dédiée à la prédiction de la présence d'eau
- une forêt dédiée à la prédiction de la présence de nuages.

Les entrées du modèle sont constituées :

- des 52 valeurs de flux spectral représentant le spectre de transit
- des variables auxiliaires décrivant le système planétaire et stellaire (masse et rayon de l'étoile, température stellaire, masse de la planète, demi-grand axe, etc.).

Les incertitudes spectrales ne sont pas utilisées à ce stade. Les forêts sont entraînées avec un nombre limité d'arbres et une profondeur contrôlée, afin de conserver des modèles simples et stables. Cette approche permet d'obtenir un premier niveau de performance robuste, servant de point de comparaison pour les modèles plus avancés.

II.2.3 Algorithme de Boosting, XGBoost

Les méthodes de boosting, quant à elles, adoptent une approche différente. Les modèles sont construits de manière séquentielle, chaque nouvel arbre cherchant à corriger les erreurs commises par les précédents. Ainsi, le modèle final accorde progressivement plus d'importance aux observations difficiles à classer. Cette propriété est intéressante dans notre contexte, où certaines signatures atmosphériques sont faibles ou masquées par le bruit, notamment en présence de nuages. Les algorithmes de boosting sont connus pour leur efficacité sur des jeux de données tabulaires et leur capacité à modéliser des relations complexes entre les variables, ce qui en fait de bons candidats pour la détection de signatures atmosphériques subtiles.

Un autre avantage important des méthodes d'ensemble est leur interprétabilité partielle. Il est possible d'analyser l'importance relative des variables utilisées par le modèle, ce qui permet d'identifier quelles longueurs d'onde du spectre ou quels paramètres physiques (température de l'étoile, masse de la planète, etc.) jouent un rôle majeur dans la prise de décision. Dans un cadre scientifique, cet aspect est particulièrement intéressant, car il permet de relier les performances du modèle à des éléments physiquement interprétables, et pas uniquement à des scores de classification.

Application dans le projet :
Dans notre travail, XGBoost est utilisé selon une stratégie similaire à celle des forêts aléatoires, avec deux modèles distincts, l'un pour l'eau et l'autre pour les nuages. Les entrées du modèle sont identiques à celles utilisées pour la forêt aléatoire, combinant les caractéristiques spectrales et les variables auxiliaires.

Les principaux hyperparamètres (nombre d'arbres, profondeur maximale, taux d'apprentissage) sont fixés de manière à obtenir un bon compromis entre performance et stabilité. Le boosting permet ici d'améliorer la détection de cas complexes, en particulier lorsque les signatures spectrales sont faibles ou partiellement masquées par le bruit.

II.2.4 CatBoost et enrichissement des caractéristiques

CatBoost est un algorithme de boosting basé sur des arbres de décision, conçu pour être particulièrement efficace sur des jeux de données tabulaires et de taille modérée. Comme les autres méthodes de boosting, il repose sur une construction séquentielle des modèles : chaque nouvel arbre est entraîné afin de corriger les erreurs commises par les arbres précédents. Cette approche permet d'améliorer progressivement les performances du modèle, en se concentrant sur les observations les plus difficiles à classer.

Un des avantages de CatBoost réside dans sa bonne gestion de données hétérogènes et dans sa capacité à exploiter efficacement des ensembles de variables variées, sans nécessiter un prétraitement excessivement complexe. Il constitue ainsi un outil adapté à des données combinant des informations spectrales et des paramètres physiques, comme c'est le cas dans ce projet.

Application dans le projet :
Dans le cadre de ce travail, CatBoost est utilisé afin d'exploiter plus finement les caractéristiques construites à partir des spectres de transit. Contrairement aux modèles précédents, plusieurs représentations des données spectrales ont été testées afin d'évaluer l'impact du feature engineering sur les performances.

Les spectres sont utilisés sous différentes formes : les valeurs moyennes du flux spectral, les dérivées spectrales (différences entre longueurs d'onde consécutives) et, dans certaines configurations, la largeur du signal spectral, calculée comme la différence entre les bornes supérieure et inférieure fournies dans les données. Ces différentes composantes sont concaténées afin de former un vecteur de caractéristiques enrichi, capable de mieux décrire la forme du spectre.

Les variables auxiliaires sont également intégrées après standardisation. Une variable dérivée supplémentaire est introduite : le rapport entre la masse de la planète et celle de l'étoile. Cette grandeur apporte une information physique complémentaire liée à la gravité et au contraste du signal de transit.

Enfin, pour CatBoost, la gestion du caractère multi-label est réalisée à l'aide d'un outil dédié permettant d'entraîner automatiquement un modèle par cible, pour la détection de la vapeur d'eau et des nuages. Les performances sont évaluées à l'aide d'une validation croisée stratifiée, ce qui permet d'obtenir une estimation plus robuste des résultats et de limiter la dépendance à un découpage particulier des données.

Dans ce projet, les méthodes d'ensemble constituent le cœur des approches de Machine Learning classique. Les forêts aléatoires fournissent une base de référence simple et robuste, tandis que les algorithmes de boosting, en particulier XGBoost et CatBoost, permettent d'exploiter des représentations plus riches des spectres et d'améliorer la détection de signatures atmosphériques faibles. Ces modèles servent de base à l'analyse des résultats présentée dans la section suivante.

II.3 Stratégies de modélisation Deep Learning

II.3.1 Motivation et Cohérence du pré-traitement

Dans un souci de rigueur scientifique et afin de garantir une comparabilité stricte avec les méthodes d'apprentissage classiques (SVM, Random Forest) présentées précédemment, nous avons appliqué exactement les mêmes protocoles de pré-traitement et de normalisation aux données spectrales. Cependant, le passage au Deep Learning est motivé par une limite fondamentale des approches classiques : ces dernières traitent le spectre comme un vecteur de variables décorrélées. Or, en astrophysique, l'information pertinente ne réside pas dans l'intensité absolue d'une longueur d'onde isolée, mais dans la topologie locale du signal. Une signature moléculaire, telle que la vapeur d'eau, se manifeste par une cohérence séquentielle faite de pentes et de creux d'absorption s'étendant sur plusieurs points voisins. C'est pour exploiter cette structure que nous nous sommes orientés vers les Réseaux de Neurones Convolutifs unidimensionnels (CNN 1D)[2]. Contrairement aux perceptrons multicouches (MLP) qui connectent brutalement chaque entrée à chaque sortie, les CNN apprennent des filtres locaux capables de détecter ces motifs géométriques invariants, simulant l'analyse morphologique qu'effectuent un expert.

II.3.2 Évolution de l'architecture : Du CNN simple au modèle Hybride

Notre démarche de modélisation s'est construite de manière itérative. Nos premières investigations se sont portées sur une architecture CNN élémentaire, prenant uniquement en entrée le spectre de transmission brut. Bien que validant la faisabilité technique de l'approche, ce modèle simple plafonnait à des scores d'Accuracy proches de 0.85 lors de nos tests préliminaires, peinant à distinguer les signaux faibles noyés dans le bruit instrumental.

Pour franchir ce premier palier, nous avons développé une architecture dite Hybride (Multi-input). L'hypothèse physique sous-jacente est que la détectabilité d'une atmosphère est conditionnée par les paramètres macroscopiques du système (rayon de la planète, température de l'étoile). Nous avons donc conçu un réseau à deux branches : une branche convolutive pour l'extraction des caractéristiques spectrales et une branche dense pour l'intégration des variables scalaires auxiliaires. La fusion de ces informations a permis un saut qualitatif immédiat, portant les scores de validation de nos premiers modèles hybrides non optimisés à environ 0.912. C'est sur cette base architecturale prometteuse que nous avons concentré nos efforts d'optimisation.

[2] Márquez-Neila, P. et al., "Supervised Machine Learning for Exoplanet Atmospheres", Nature Astronomy, 2, 719–724, 2018.

II.3.3 Analyse théorique des stratégies de sortie

Un axe majeur de notre recherche a porté sur la définition de la couche de sortie, qui conditionne la manière dont le modèle interprète la physique du problème. Nous avons confronté deux paradigmes distincts.

La première approche, dite Multi-label à 2 neurones, postule l'indépendance physique des phénomènes. La couche de sortie est composée de deux unités sigmoïdes distinctes optimisant deux pertes binaires parallèles. L'avantage théorique est la simplification du problème : le modèle apprend à reconnaître la signature de l'eau sans se soucier explicitement de l'état nuageux. C'est une approche efficace mais qui suppose que les signaux se superposent linéairement.

La seconde approche, dite Multi-classe à 4 neurones, envisage le problème sous un angle combinatoire et systémique. La sortie est une couche Softmax représentant l'espace des quatre états exclusifs du système : rien, eau seule, nuages seuls, ou présence eau et nuages. Cette modélisation est plus riche théoriquement car elle force le réseau à apprendre des signatures conjointes. L'hypothèse est que la classe mélange eau et nuages possède une signature spectrale propre, complexe et non linéaire, où les nuages agissent comme un filtre modifiant la morphologie des raies d'eau. Nos résultats finaux ont montré que cette approche capturait mieux les interactions fines entre le bruit nuageux et les signatures moléculaires, surpassant légèrement l'approche par indépendance.

II.3.4 Limites de l'augmentation de données et Protocole d'optimisation

La consolidation de nos résultats a nécessité une méthodologie rigoureuse. Dans une tentative initiale d'améliorer la généralisation, nous avons exploré une stratégie d'augmentation de données synthétiques (ajout de bruit gaussien, décalages). Contrairement à son efficacité en vision par ordinateur, cette technique s'est révélée contre-productive ici : l'altération artificielle des spectres dégradait les structures fines des raies d'absorption, entraînant une divergence de l'apprentissage. Nous avons donc abandonné cette piste.

Nous avons privilégié une optimisation par Grid Search sur les hyperparamètres du modèle hybride (taux d'apprentissage, taille de batch, architecture dense). Pour garantir la fiabilité statistique des résultats et s'affranchir de l'aléa d'initialisation des poids, chaque configuration a été évaluée sur plusieurs entraînements indépendants (runs multiples). C'est l'analyse de l'écart-type des performances qui a guidé notre sélection, nous permettant de retenir la configuration la plus stable et robuste, et non simplement celle ayant obtenu un score élevé par chance.

II.3.5 Performances finales et Convergence

Au terme de ce processus d'optimisation, nos modèles hybrides finaux marquent une progression significative par rapport aux itérations précédentes. Le modèle optimisé atteint des scores sur le jeu de test de 0.951 pour le modèle multi-label et jusqu'à 0.968 pour le modèle multi classes. L'analyse comparative des dynamiques d'apprentissage, illustrée par les courbes de fonction de coût (*Loss*) et de précision (*Accuracy*), permet d'affiner notre compréhension du comportement des deux architectures.

Concernant le *Modèle 1* (architecture Multi-label à 2 neurones), nous observons une phase d'apprentissage rapide lors des premières époques, caractérisée par une chute abrupte de la *loss*. Bien que le modèle atteigne un plateau de performance élevé avec un score de 0.951, les courbes de validation montrent une légère instabilité résiduelle ou un écart plus marqué vis-à-vis du jeu d'entraînement par rapport au second modèle. Cela suggère que l'indépendance forcée des sorties limite marginalement la capacité du réseau à généraliser parfaitement sur les cas ambigus où les signatures spectrales sont fortement altérées.

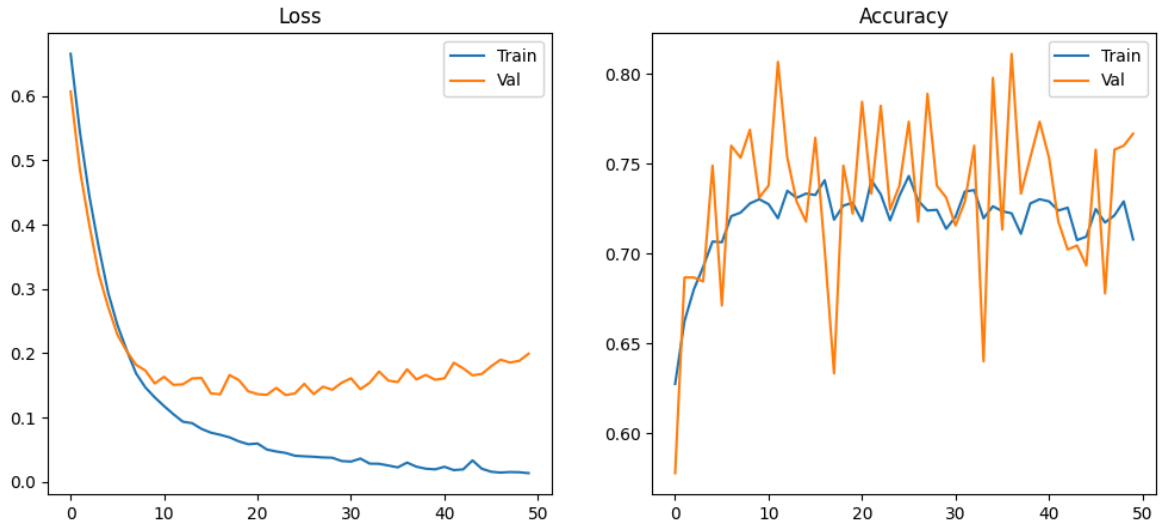

À l'inverse, le *Modèle 2* (architecture Multi-classe à 4 neurones) présente un profil de convergence plus robuste et régulier. La courbe de validation épouse plus fidèlement celle d'entraînement, et le minimum de la fonction de coût est atteint avec une valeur absolue inférieure. Cette meilleure dynamique confirme que la modélisation à 4 états exclusifs permet au réseau de mieux structurer son espace latent : en apprenant les corrélations entre les classes plutôt qu'en les traitant isolément, le modèle optimise sa descente de gradient et atteint une finesse de décision supérieure, matérialisée par le score final de 0.968. Dans les deux cas, l'absence de remontée significative de la courbe de perte de validation après la stabilisation valide le calibrage de nos mécanismes de régularisation (Dropout), qui ont efficacement endigué le sur-apprentissage malgré la complexité inhérente aux réseaux profonds.

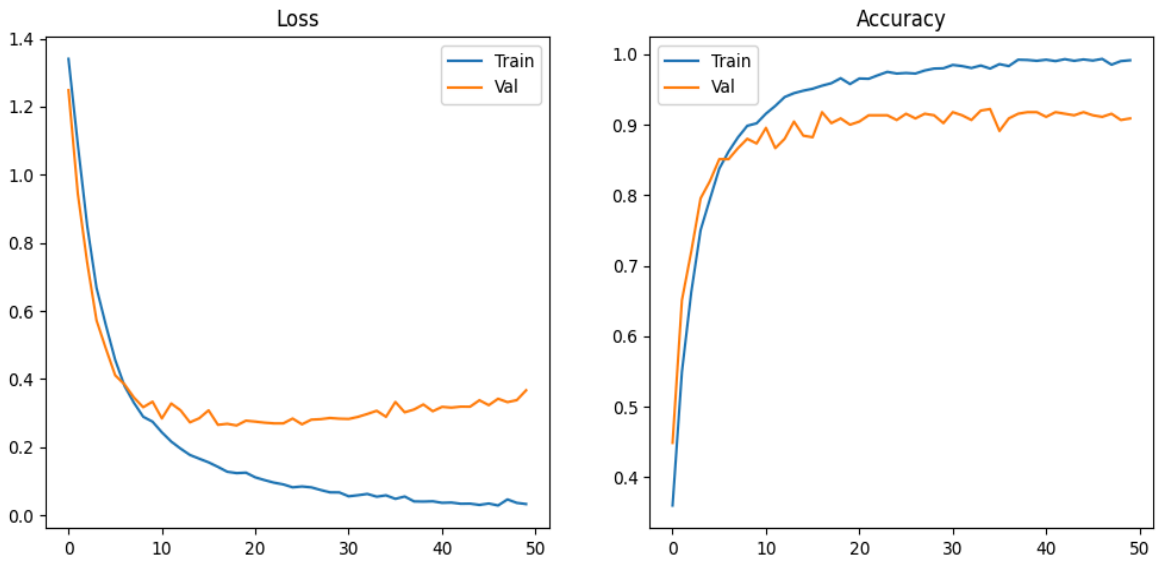

Les poids des modèles finaux ont été sauvegardés avant que le modèle fasse du sur-apprentissage comme on peut le voir dans ces courbes.

II.4 Protocole d'évaluation

Afin d'évaluer de manière fiable les performances des différents modèles, un protocole d'évaluation commun a été mis en place pour l'ensemble des approches étudiées. L'objectif est de garantir une comparaison équitable des modèles et de limiter les biais liés à la distribution des données.

Le jeu de données étant formulé comme un problème de classification binaire multi-label (présence ou absence d'eau, présence ou absence de nuages), une attention particulière a été portée à la stratification des données. Les jeux d'entraînement et de validation sont construits de manière à respecter les proportions des différentes combinaisons de labels [0,0], [1,0], [0,1] et [1,1]. Cette stratification permet d'éviter qu'un modèle ne soit favorisé par une surreprésentation d'une classe particulière et garantit une évaluation plus représentative des performances globales.

Dans un premier temps, un découpage simple du jeu de données est utilisé, en séparant aléatoirement les observations en un ensemble d'apprentissage (environ 80 %) et un ensemble de validation (environ 20 %). Ce découpage permet d'obtenir une première estimation des performances des modèles. Afin d'obtenir une évaluation plus robuste, en particulier pour les méthodes d'ensemble les plus avancées, une validation croisée stratifiée à cinq plis est également mise en œuvre. La stratification est alors réalisée séparément pour chaque tâche de classification (eau et nuages), de manière à conserver un équilibre entre les classes dans chaque sous-ensemble.

Pour l'évaluation des performances, la métrique officielle utilisée dans le cadre du défi est la précision (accuracy), telle qu'elle est définie sur la plateforme Kaggle. Cette métrique est

utilisée pour le classement des modèles et constitue la référence principale pour comparer les performances finales.

Néanmoins, d'un point de vue méthodologique, d'autres métriques telles que le F1-score sont souvent plus adaptées pour analyser finement des problèmes de classification binaire, en particulier lorsque les erreurs de type faux positifs et faux négatifs n'ont pas le même impact scientifique. Dans ce travail, ces métriques sont discutées à titre conceptuel afin de contextualiser les choix méthodologiques, mais l'analyse quantitative des résultats repose sur la précision fournie par Kaggle.

Enfin, pour certains modèles, notamment CatBoost, un mécanisme d'arrêt anticipé (early stopping) est utilisé. Celui-ci consiste à interrompre l'apprentissage lorsque les performances sur les données de validation cessent de s'améliorer, ce qui permet de limiter le sur-apprentissage et d'obtenir des modèles plus stables.

III. Analyse des Résultats

Dans cette partie, nous allons analyser les performances qualitatives de nos modèles, ainsi qu'une interprétation des prédictions à la lumière des atmosphères planétaires.

III.1 Analyse Exploratoire (EDA)

Avant d'analyser les performances des modèles, il peut être utile de visualiser ce que les algorithmes "voient". Nous avons donc calculé le spectre moyen des observations classées positivement pour l'eau, et celui des observations classées positivement pour les nuages, comparés à leurs contreparties négatives.

Signature de l'eau : la visualisation des moyennes met en évidence des bandes d'absorption claires. Les spectres contenant de l'eau présentent des creux caractéristiques (c'est-à-dire une augmentation de la profondeur de transit) à des longueurs d'onde spécifiques, notamment autour de 1.4 et 2.8µm, ainsi qu'après 5µm. Le modèle dispose donc d'un motif morphologique distinct, une forme à détecter.

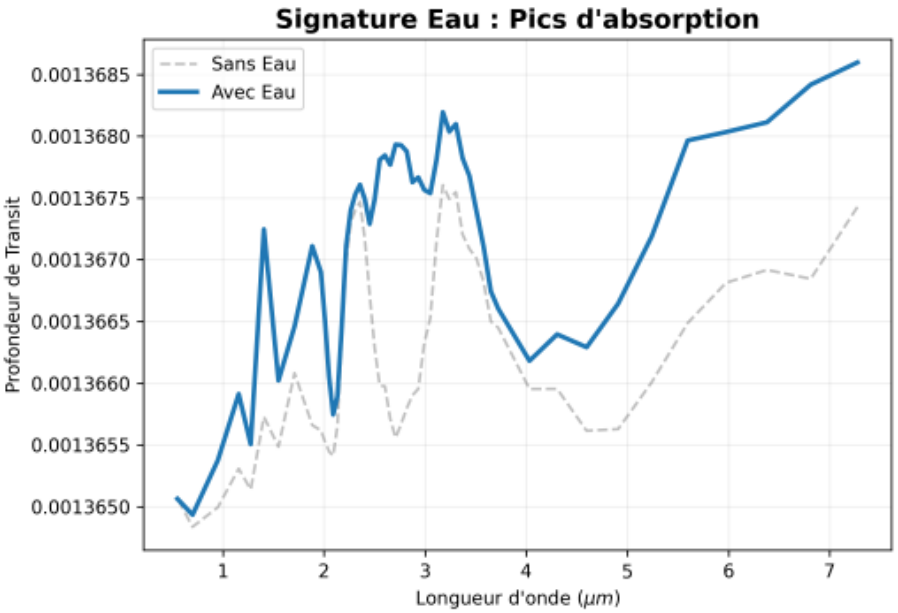

Signature des nuages : l'effet des nuages est différent de celui de l'eau. Lorsqu'on compare des spectres nuageux avec des spectres non nuageux, on n'observe pas de nouvelles raies, mais une modification globale de la dynamique du signal. Les nuages ont donc une tendance à aplatir le spectre et à réduire l'amplitude des pics d'absorption car ils augmentent l'opacité de l'atmosphère à toutes les longueurs d'ondes. Le défi pour les modèles va donc être de distinguer un spectre plat dû aux nuages d'un spectre plat à cause d'une atmosphère fine ou inexistante.

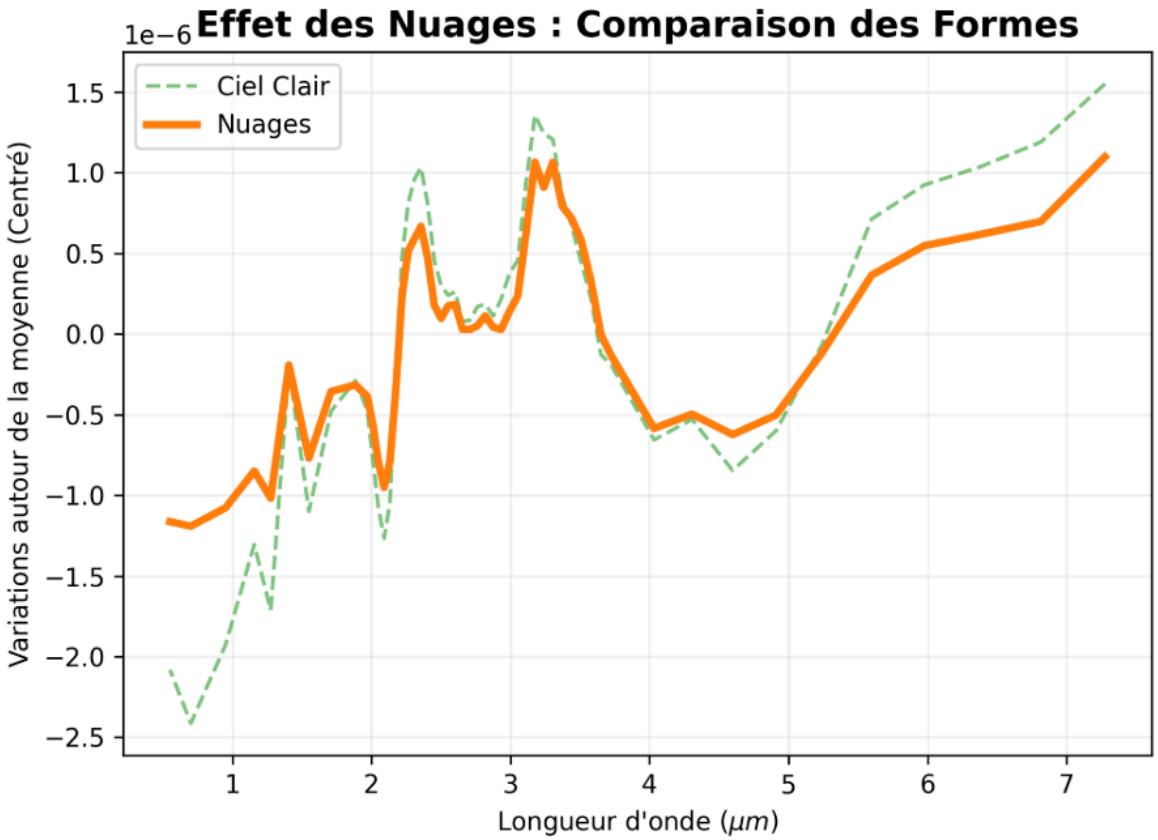

III.2 Performance des Modèles

L'évaluation des performances finales des différents modèles repose principalement sur les scores obtenus sur la plateforme Kaggle, qui fournit un cadre standardisé et indépendant pour comparer les approches proposées dans le cadre du défi. Le jeu de test utilisé par Kaggle, distinct des données d'entraînement, permet ainsi d'évaluer la capacité des modèles à généraliser à de nouvelles observations. Toutefois, les modalités exactes de construction du jeu de test et la distribution précise des données ne sont pas connues. De plus, la métrique utilisée pour le classement est l'accuracy, qui, bien qu'adaptée à la comparaison des modèles dans le cadre du challenge, ne permet pas à elle seule de caractériser finement leur comportement. Les résultats présentés permettent avant tout de comparer les modèles entre eux, mais ne constituent pas une évaluation complète de leur qualité scientifique.

III.2.1 Synthèse des résultats

Le tableau ci-dessous présente les scores globaux (Score Kaggle) obtenus par les principales architectures développées.

Modèle	Type d'Architecture	Score Kaggle
Baseline	Méthode d'Ensemble (Bagging)	0.84
CNN de base	Deep Learning - normalisation initiale	0.85
XGBoost	Gradient Boosting - normalisation initiale	0.89
CatBoost	Gradient Boosting - normalisation initiale	0.92
XGBoost	Gradient Boosting - normalisation locale	0.92
CatBoost	Gradient Boosting - normalisation locale	0.94
CNN optimisé	Deep Learning (Convolutif) - Normalisation Locale	0.97

III.2.2 Analyse des performances

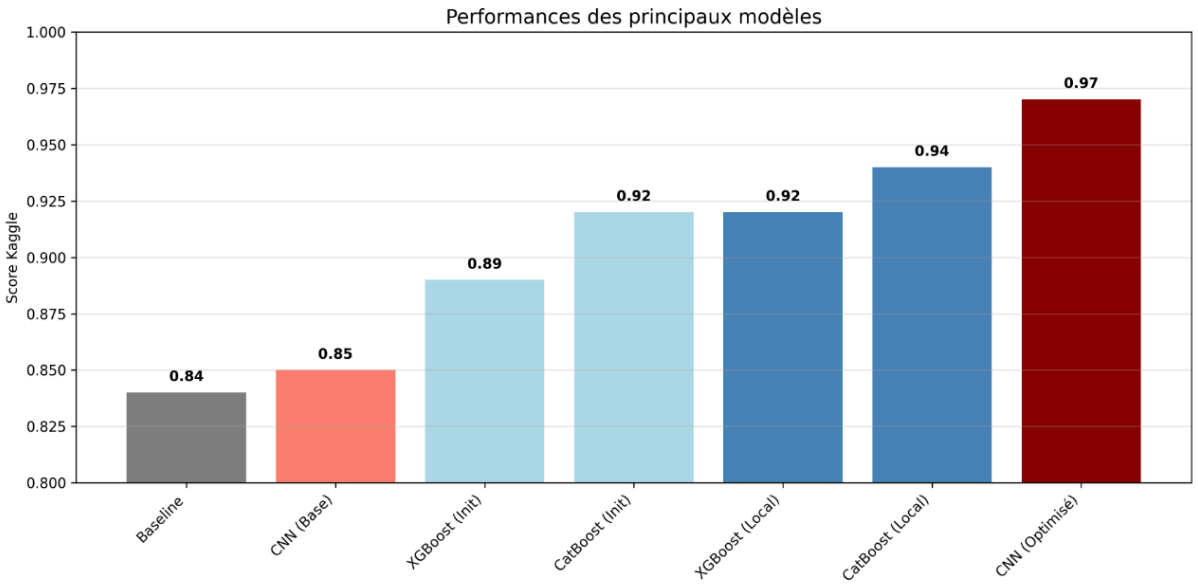

L'analyse de cette progression permet de dégager trois conclusions majeures :

L’échec du deep learning naïf : avec un score de 0.85, le réseau de neurone de base (entraîné sur les données normalisées globalement, comme dans la baseline), peine à dépasser celle-ci et fait moins bien que les méthodes de boosting pourtant s’entrainant après cette même normalisation (plus de 0.89). Toutefois, cette comparaison doit être nuancée : contrairement aux modèles de boosting qui sont souvent performants "par défaut", ce premier réseau de neurones n'a bénéficié d'aucune optimisation de ses hyperparamètres.
Cela est assez logique, car les réseaux de neurones sont sensibles à l'échelle. Sans la normalisation par instance, le CNN remarque principalement la luminosité de l’étoile (qui varie de plusieurs ordres de grandeur) plutôt que la plus légère variation due à l’atmosphère. C'est donc ce bruit dominant qui empêche le modèle de converger vers de meilleures et plus fines estimations.

L’impact de la normalisation locale (la physique dans le modèle) : l’introduction de la normalisation locale (Z-score, détaillée plus haut), transforme rapidement les résultats.
Pour les modèles de boosting, elle permet un gain de 2 à 3 points.
Pour le CNN, l’effet est encore plus impressionnant : un gain de 12 points (de 0.85 à 0.97). Cela confirme que l’information pertinente, utilisée par le modèle, ne réside pas dans les valeurs absolues du flux, mais bien uniquement dans sa forme relative. En forçant le modèle à ignorer l'intensité moyenne (liée au rayon de l'étoile), on lui permet de se focaliser sur les motifs d'absorption.

L’énorme écart final du CNN optimisé (0.97) : une fois correctement alimenté (normalisation locale) et bien paramétré avec une gridSearch, le CNN dépasse toutes les approches classiques.
Contrairement au XGBoost / CatBoost qui traitent les 52 points spectraux comme des variables indépendantes (sans notion d'ordre), le CNN exploite la cohérence séquentielle du spectre. Il utilise des filtres de convolution pour détecter des motifs locaux caractéristiques des molécules, offrant une robustesse au bruit que les arbres de décision ne peuvent égaler.

III.3 Analyse Métier

Au-delà de la performance brute, il est intéressant de vérifier si les modèles s'appuient sur des corrélations physiques réelles ou sur des biais statistiques. Nous avons pour cela analysé l'importance des variables (Feature Importance) de nos modèles de Boosting (CatBoost/XGBoost).

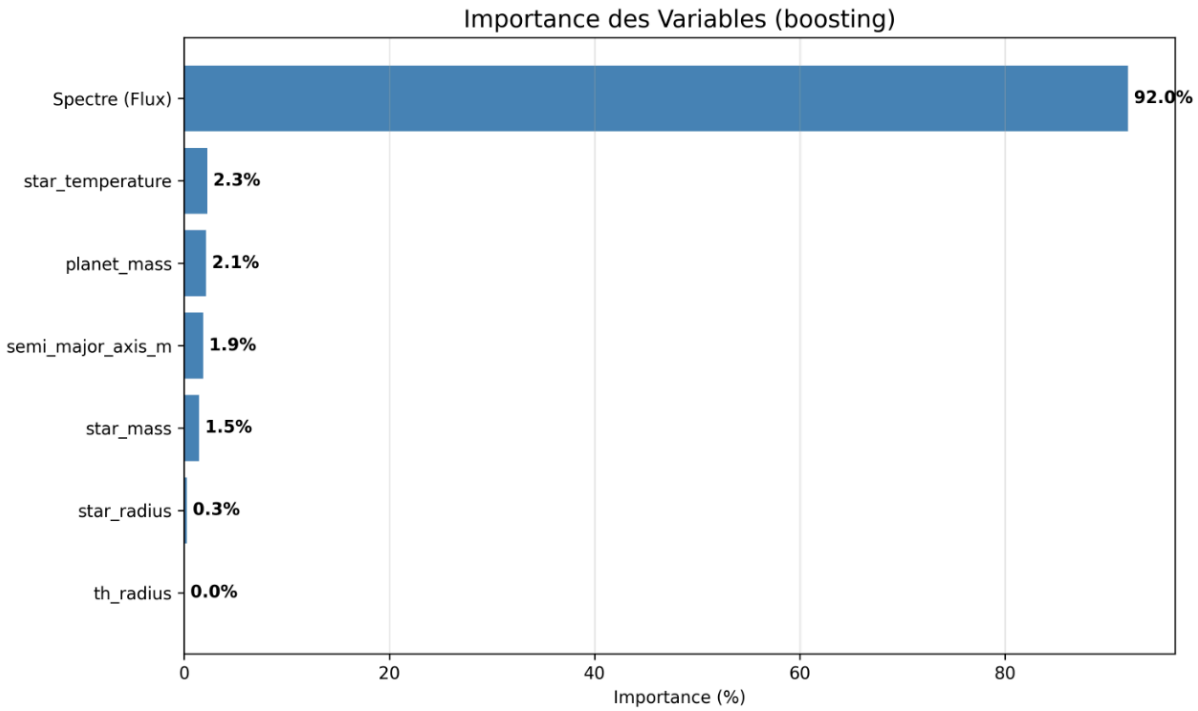

III.3.1 Hiérarchie des prédicteurs

L'analyse de la contribution de chaque variable à la décision finale révèle une hiérarchie cohérente avec la théorie astrophysique :

Prédominance des points spectraux clés : comme imaginé, les variables les plus discriminantes sont les flux mesurés à certaines longueurs d'onde spécifiques (notamment dans l'infrarouge). Cela confirme que le modèle détecte bien les bandes d'absorption moléculaires et ne se base pas uniquement sur le contexte.

L’importance de la température de l’étoile : parmi toutes les variables auxiliaires, la température de l’étoile est toujours classée dans le top 3 des prédicteurs les plus importants. Cela signifie que le modèle se fait un premier apriori, et pondère la probabilité de présence de l’eau avant même de regarder le spectre (si la planète est très chaude ou très froide).

III.3.2 Analyse des Erreurs et Cas Limites

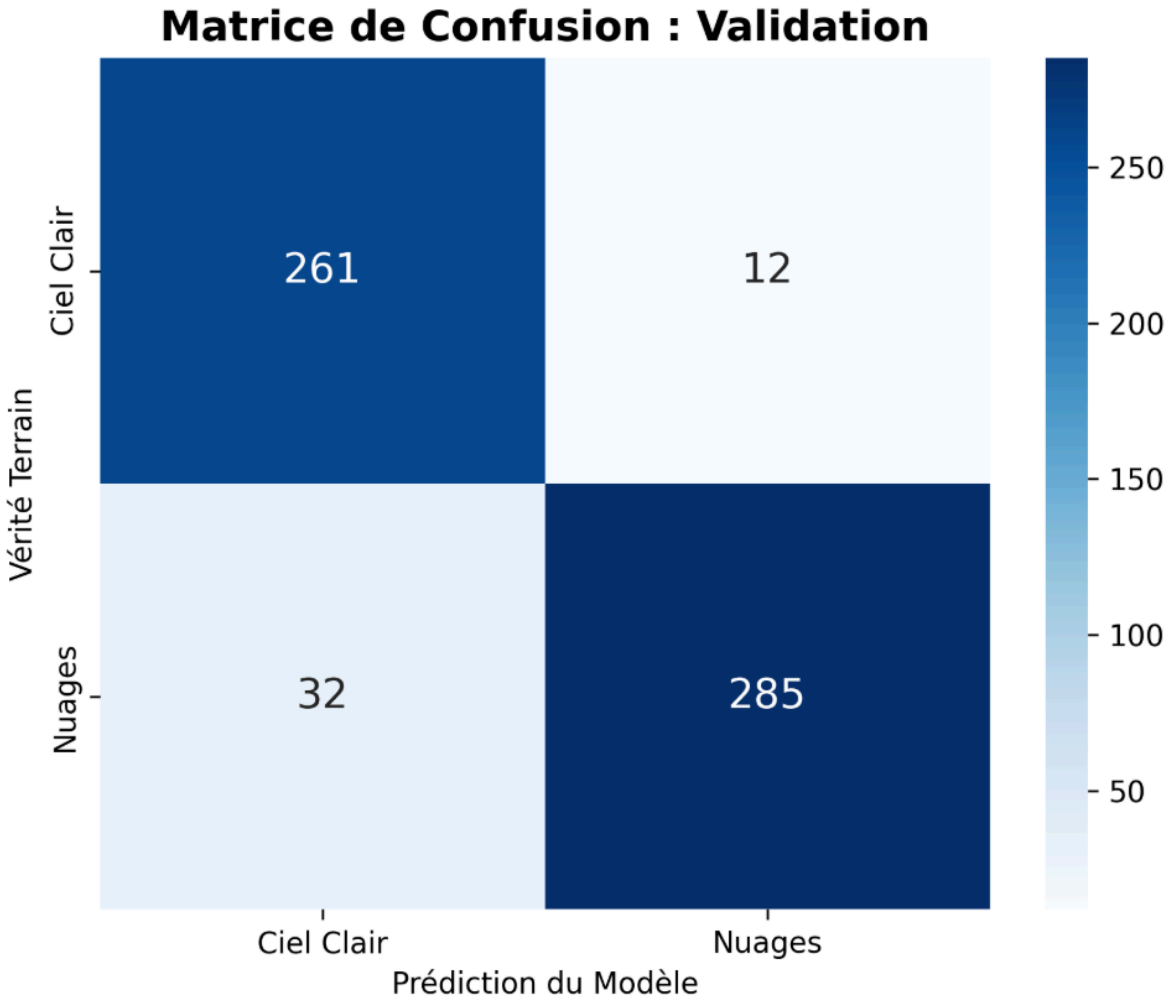

L'étude de la matrice de confusion et des cas mal classés du modèle CNN optimisé met en lumière deux difficultés principales fréquentes en spectroscopie de transit :

La confusion "Nuages vs Gravité" : La majorité des erreurs sur la classe "Nuages" sont des Faux Négatifs. Un spectre plat peut être causé par une couche nuageuse opaque, mais aussi par une atmosphère lourde, ce qui fait que le modèle peut peiner à distinguer ces 2 possibilités, illustrant le problème connu de "dégénérescence"[3].
Cette ambiguïté ne constitue pas une faiblesse spécifique de notre approche : des travaux récents ont montré que même des modèles de Deep Learning entraînés sur des spectres simulés rencontrent les mêmes limites face à ces dégénérescences physiques.

Le rapport signal/bruit : les erreurs se concentrent sur des petites planètes, qui orbitent autour d'étoiles bruyantes. Dans ces cas précis, la signature de l'atmosphère est infime (quelques parties par million). Elle est si faible qu'elle a la même intensité que les parasites naturels du télescope (le bruit). Le signal utile est donc noyé dans le bruit de fond, ce qui empêche le modèle de distinguer une véritable trace d'eau d'une simple fluctuation aléatoire.

[3] Madhusudhan, N., “Exoplanetary Atmospheres: Key Insights, Challenges, and Prospects”, Annual Review of Astronomy and Astrophysics, 57, 617–663, 2019.

IV. Conclusion Générale

Ce projet s'inscrivait dans le cadre du défi IA 2025, pour la préparation de la mission spatiale ARIEL, avec pour objectif d'évaluer la capacité de l'Intelligence Artificielle à automatiser l'analyse de spectres d'exoplanètes. À travers l'exploration des données, la modélisation et l'analyse critique des résultats, cette étude démontre que l'efficacité des modèles repose sur la synergie entre la connaissance physique du signal et les capacités statistiques des approches algorithmiques.

La supériorité de l'approche hybride (Deep Learning + Physique) : le résultat majeur de cette étude est la performance atteinte par le réseau de neurones convolutif (CNN) optimisé, avec un score de 0.97. Cependant, ce succès ne repose pas uniquement sur la complexité de l'algorithme. La comparaison avec les modèles "naïfs" a prouvé que c'est en partie le pré-traitement guidé par la physique (la normalisation locale par spectre) qui a débloqué le potentiel du Deep Learning. Nous avons démontré que pour détecter des traces chimiques, l'IA doit notamment apprendre à ignorer l'intensité absolue du flux stellaire pour se concentrer exclusivement sur la morphologie des bandes d'absorption.

L'IA comme outil de validation physique : l'analyse de l'interprétabilité des modèles a révélé que les algorithmes ne se comportent pas comme des boîtes noires. Ils confirment, par l'apprentissage statistique, des phénomènes physiques attendus ; l'importance critique de la température stellaire pour prédire la stabilité thermodynamique de l'eau ; la difficulté intrinsèque à distinguer des nuages d'une atmosphère lourde (dégénérescence), validant la difficulté théorique de ces observations.

Bien que les résultats soient excellents sur ce jeu de données simulées, certains obstacles sont encore présents. Concernant le rapport signal/bruit, les performances chutent sur les petites planètes , suggérant que des méthodes de débruitage plus avancées (comme les Auto-Encodeurs) seront nécessaires. Nos modèles ont été entraînés sur un jeu de données artificiellement équilibré (50% de cas positifs pour l'eau, pareil pour les nuages). Or, dans l'univers réel, la distribution est probablement très asymétrique (les exoplanètes avec de l'eau liquide sont statistiquement rares). L'application directe de ce modèle en conditions réelles exposerait la mission au paradoxe des faux positifs : un classifieur optimisé sur une répartition 50/50 risque de surestimer la présence d'eau lorsqu'il est confronté à une population où l'événement cible est rare. Une étape de re-calibration des probabilités serait donc nécessaire avant tout déploiement opérationnel. À terme, ces modèles pourraient servir à trier rapidement les observations d'ARIEL, afin d'identifier les planètes les plus intéressantes, qui seraient ensuite étudiées plus en détail à l'aide de méthodes physiques classiques.

V. Bibliographie

(1) Tinetti, G., Drossart, P., Eccleston, P., et al.,
“ARIEL: Enabling planetary science across light-years”,
Experimental Astronomy, Vol. 46, pp. 135–209, 2018.
https://doi.org/10.1007/s10686-018-9598-x

(2) Márquez-Neila, P., Fisher, C., Sznitman, R., & Heng, K.,
“Supervised machine learning for analysing spectra of exoplanetary atmospheres”,
Nature Astronomy, Vol. 2, pp. 719–724, 2018.
https://arxiv.org/abs/1806.03944

(3) Madhusudhan, N.,
“Exoplanetary Atmospheres: Key Insights, Challenges and Prospects”,
Annual Review of Astronomy and Astrophysics, Vol. 57, pp. 617–663, 2019.
https://arxiv.org/abs/1904.03190